

Гермес как личный инструмент

Скиллы, профили, оркестрация локальных моделей и пайплайны за ноль рублей. Все цифры - из живых прогонов на этой машине.

Локальный стенд

0 ₽

RTX 4060 8 ГБ · 20 моделей · минимум внешних расходов

Ноль рублей = минимум расходов, а не ноль трат: мозг агента - дешёвый pay-per-token API, всё тяжёлое и чувствительное (речь, сканы, картинки, поиск) - локально на вашей карте.

Что разберём, и где об этом читать

1. Силлы

Чем силл отличается от промпта и как агент подтягивает знания сам

2. Профили и уровни

Изоляция по смыслу, клон обязателен, проектные силлы и их грабли

3. Оркестрация моделей

Кому какая работа, выгрузка VRAM как условие работоспособности

4. Кванты и лицензии

Bartowski, размер против поведения модели, проверка карточки

5. Пайплайн аудио

Расшифровка, диаризация, честное сравнение двух движков

6. Пайплайн документов

PDF и сканы в Markdown, грабли запуска, свежие кандидаты

7. Границы и орс-практика

Где локальный стек останавливается и где тот же подход уже в бою

8. Итоги

Что взять с собой сегодня же, hands-on-блок с командами в сценарии

СТЕНД

Стенд одним взглядом

Одна машина, одна карта, ноль внешних сервисов. Всё, что дальше на слайдах, крутится здесь.

Железо

RTX 4060 8 ГБ VRAM - единственный дефицитный ресурс. Диск - просто хранилище, сеть - только для скачивания весов

Каталог

20 моделей в LM Studio, 49.8 ГБ на диске: текст, зрение, речь, диаризация, эмбеддеры - по одной на этап

Серверы

LM Studio на :1234 для текста, отдельный llama.cpp на :8017 для OCR. Больше ничего не поднято

Цена

0 ₽/мес: ни подписок, ни API-ключей, ни лимитов. Карта окупилась давно

БЛОК 1

Скилл или промпт

Единственная разница, без которой весь остальной разговор не имеет смысла: что происходит с инструкцией после вызова.

Промпт

Вы написали инструкцию

Агент выполнил вызов

Инструкция умерла - нигде не участвует

Скилл

SKILL.md лежит на диске с описанием

Агент сам находит его по описанию задачи

Живёт и работает в каждом подходящем вызове


Правило второго раза

Задача повторяется, нужен одинаковый результат, или вы объясняете коллеге последовательность второй раз - пора оформлять это в скилл. Практика: 35 скиллов взяты из репозитория вендоров, 112 написаны под свою инфраструктуру - и один диспетчер, который решает, что грузить под задачу.

Подробнее: [29 скиллов на четыре ступени объяснения](#) · [Цикл по книге Инфанте: движок, чат-бот, агент](#)

Откуда берутся скиллы

Три источника и один диспетчер. Практика DevOps-набора: 35 из репозиториев вендоров, 112 написаны под свою инфраструктуру.



Почему это работает

Агент не читает все скиллы целиком: он читает заголовки и описания, экономя контекст. Диспетчер - обычный SKILL.md с описанием, когда какой профильный скилл подключать.

БЛОК 2

Профили как изоляция

Скиллы конфликтуют между собой не по именам, а по смыслу. Два контейнера - и контекст каждого чист.

Профиль: торговля

Wildberries, Ozon

закупка, цены, поставки

свои скиллы, ничего лишнего в контексте

Профиль: аудит и конференции

расшифровка, диаризация

протоколы

второй набор скиллов, первый о нём не видит

Клон обязателен

Без него профиль пустой и модель не резолвится. Токены ботов остаются у исходного профиля, иначе два профиля будут драться за апдейты.

Не безопасность

Профиль изолирует навыки и настройки, но не файлы на диске. Для изоляции данных нужны контейнеры и права доступа.

Подробнее: [Профиль на проект](#) · [Профили, скиллы и A2A](#)

Скиллы живут на трёх уровнях

Проектный перекрывает профильный - это поведение заложено в коде, не договорённость.



Проект: `.hermes/skills` или `.agents/skills`

только этому проекту · перекрывает профильный · тег `project` в промпте



Профиль: `skills/` в профиле

всем проектам профиля · базовый уровень



Внешний каталог: список папок в конфиге

нескольким профилям сразу · ниже профиля

Два барьера, и выглядят одинаково

Доверие. Нужен `hermes skills trust` в корне репо, решение одноразовое. Без него агент не знает, что скиллы есть.

Корень. Поиск идёт вверх до ближайшего `.git`. Папка вне репозитория корня не имеет.

Проверяемо, не догадка

В коде две константы `PROJECT_SKILLS_SUBDIRS`, функция `get_project_skills_dirs`, и комментарий в сборщике промпта: `project-local skills have highest precedence`.

Кому какая модель

Спрашивать модель, умеет ли она то, что нужно, дешевле, чем заставлять её делать.

20

моделей в каталоге LM Studio, 49.8 ГБ на диске

0

reasoning-токенов у granite на логических задачах

297

токенов рассуждения у gemma из лимита 300, ответ пустой

granite + зрение + два эмбединга: что лежит на карте




0 ГБ8 ГБ VRAM · занято 7.5 · скорость granite падает с 81 до 18.9 токена/с, в 4.3 раза

Подробнее: [Десять локальных моделей на RTX 4060](#) · [Model-Routing: агент выбирает модель сам](#) · [Бенчмарки врут красиво](#)

Выгрузка моделей из VRAM

Пайплайн обязан освобождать память между шагами. Это не оптимизация, это условие работоспособности на 8 ГБ. Чем проще модель, тем больше вокруг неё обвязки - и выгрузка это часть обвязки, не хак.



Ошибка не воспроизводится на маленьком файле

Без выгрузки пайплайн падает на длинном документе, а на первых пятидесяти работает прекрасно. Отладка занимает час, потому что на коротком прогоне всё хорошо.

БЛОК 3, ПРОДОЛЖЕНИЕ

Эмбеддер под поиск: свежий кандидат

EmbeddingGemma 2: карточка дала предсказание, замер дал вердикт. 740M = 270M текст + 170M зрение + 300M аудио, Apache 2.0.




Где не нужен

Скриншот с печатным текстом: OCR даёт тот же поиск. Текстовый эмбеддер тоже не заменяет: у bge-m3 нерелевант 0.28, у Gemma 0.50 - рабочее окно уже. Статус: внедрена вторым слоем, индекс картинок рядом с текстовым индексом.

Разбор + скрипт: [EmbeddingGemma 2, 53 картинки за 8 секунд](#) · [RAG в глубину](#).

Как эмбеддер встаёт рядом с OCR

Два индекса на один документ: текстовый ищет слова, эмбединговый ищет картинки. Запрос идёт в оба, ответы сливаются.



БЛОК 3А

Bartowski: квант это не один файл

Коллекция квантизованных моделей на Hugging Face. Влезает в 8 ГБ именно квант, а не сама модель.

Пример: OvisOCR2.

IQ2_M - лёгкое, качество проседает

359 МиБ

Q4_K_M - рабочая лошадка (мой
стенд: 505 МиБ на Abiray)

532 МиБ

Q8_0 - если есть запас, разница с Q4
не всегда видна

776 МиБ

bf16 - эталон: качество то же, памяти
вдвое больше, не брать

1.4 ГБ

2464

репозитория в коллекции

1867

из них готовые GGUF

4x

разница между IQ2_M и bf16 у одной модели

Размеры по коллекции Bartowski; локальный стенд собран на Abiray, у него Q4_K_M 505 МиБ.

Подробнее: [Неделя GGUF от Bartowski](#) · [Что реально качают](#) · [Тысяча квантов, один подходит](#)

Лицензия важнее размера

Читать карточку модели до скачивания, а не после внедрения.



CC-BY-4.0

pyannote community-1. Можно всё: коммерция, прод, модификации. Единственное условие - указать авторов там, где вы выкладываете результат. Для внутреннего стенда условие выполняется само



openmdw-1.1

Nemotron 3 Diarization от NVIDIA. Лицензия Linux Foundation для весов моделей: коммерция, модификации, редистрибуция - всё разрешено, условий на выходы модели нет. Простейший случай: читаем один раз и работаем



openrail

Surya-2. Разрешено всё, кроме перепродажи модели как услуги. Встраивать в свой продукт можно, продавать саму модель как SaaS - нет. Для внутреннего использования - свободно



Нет лицензии

«Исходники открыты» без лицензии = по умолчанию все права защищены. Юридически использовать нельзя, даже внутри компании. Красный флаг, проходить мимо

БЛОК 4

Пайплайн аудио: три шага

Расшифровать, разделить по спикерам, оформить. Без второго шага получается стена текста.



Ловушка флага языка

Whisper не останавливается на неверном определении, а выдаёт уверенный текст. На слух почти правильно, но слов реальных там нет. Проверка: фрагмент на 10 минут и пара слов, которые точно знаешь.

Подробнее: [локальные модели в закрытом контуре](#)

Nemotron против ruannote: честно

Nemotron, 3 ч 5 мин аудио

17 с

ruannote, тот же файл

в 15-25 раз дольше

Плюсы

107 млн параметров, 379 МБ на диске, 266 МБ в VRAM, коммерческое использование разрешено (openmdw-1.1)

Дефекты


В 4 из 5 файлов дали фантомных спикеров. Не определяет людей, только фреймы речи. В плагине как бэкенд не подключён

Файл	Кластеров	Где чисто
Встреча 30 мин	4	да
Лекция 41 мин	8	нет, спикеров было 2
Лекция 35 мин	6	нет, спикеров было 2
Подкаст	5	нет

Лечится фильтром: кластеры короче 30 секунд отбрасываются, скрипт сам сообщает о таких. Код открыт: [gitflic.ru/manve-sulimo2/shturman-meeting](https://github.com/manve-sulimo2/shturman-meeting) - установка, плагин, 16 ADR, 197 тестов

Кто говорил: отпечатки голоса

Встреча два часа, шесть выступающих. Расшифровать умеет всякий - вопрос, кто где говорил. Разбирать по паузам можно один раз, а можно снять голосовой отпечаток - и дальше атрибуция ставится сама.



Разовая цена - потом бесплатно

Один раз: сверить «голос 3» с тем, кто вёл блок вопросов. Дальше атрибуция ставится сама: отпечаток того же голоса - та же метка. 26 МБ модель - меньше, чем один скриншот PNG

Чего это не делает

Не называет имена - только группы «один голос». Схожесть голосов родных и коллег на грани: редкие склейки проверяются по контексту реплик

Фильтр фантомов: 26 кластеров → 17 спикеров

Nemotron на лекциях плодит короткие кластеры-фантомы. Лечится одной строкой, цена - четыре пятых процента речи.

Кластеров до фильтра

26

Кластеров после (короче 30 с - вон)

17

30 с

порог: кластер короче - фантом

0.78%

речи потеряно фильтром по всем файлам

0

настроек: скрипт сам считает и сам сообщает

Почему 0.78% - это дешево


Фантомные кластеры - это обрывки фраз по 5-15 секунд, не несущие смысла. Настоящие реплики длиннее минуты, фильтр их не трогает. Проверено на пяти файлах: встреча 30 мин, две лекции, подкаст.

БЛОК 5

OCR-история 1 из 3 · РАБОЧИЙ ПАЙПЛАЙН: OvisOCR2, он в проде

PDF и сканы в Markdown

Не конвертация, а понимание структуры: заголовки, списки, таблицы, формулы. Потребители результата: агенты, поиск по архиву, протоколы. Картинки страниц параллельно уходят в эмбединг-индекс Gemma - слой со слайда 11.




БЛОК 5, ПРОДОЛЖЕНИЕ

OCR-история 1 из 3 · РАБОЧИЙ ПАЙПЛАЙН: как он устроен

Схема OCR-контура

Что стоит где и почему две грабли вообще возможны: у контура три точки отказа.



БЛОК 5, ПРОДОЛЖЕНИЕ

OCR-история 2 из 3 · ГРАБЛИ ЗАПУСКА: того же рабочего пайплайна

Два часа на грабли запуска

Обе ошибки выглядят как «модель сломана». Обе лечатся одной строкой в команде.

Обёртка LM Studio

Запросы с картинками отваливаются по соединению. OCR-сервер держим на отдельном llama.cpp, порт 8017. Проверка живости: `curl http://127.0.0.1:8017/health`

Unix-слэши в пути

Нативный бинарник отвечает «файл не найден», хотя файл рядом. Пути только C:/...

Мой стенд


OvisOCR2 Q4_K_M 505 МиБ (Abiray), 0.8B, apache-2.0, 10-12 с на страницу. Печать страниц в картинки строго 300 dpi.

БЛОК 5, OCR

OCR-история 3 из 3 · КАНДИДАТ: проверили, в пайп НЕ взяли

GLM-OCR: обещали 1.86 стр/с, получили 0.069

MIT, 0.9B, Q8_0 906 МиБ + mmpoj 462 МиБ. Замер на этой машине: 4 страницы ПМИ, 300 dpi.

Кандидат, не замена: рабочий OCR - OvisOCR2 (505 МиБ). Этот слайд - про проверку обещаний в карточках

При этом модель быстрая

Генерация **194-212 tok/s**, prompt eval **1780 tok/s**. Узкое место - картинка и длина ответа. Автосчёт подозрительных мест (смешанная кириллица+латиница): GLM 18 против Ovis 34 на 4 страницы - но часть GLM-овских попаданий это верное распознавание настоящей латиницы, верить метрике на глаз

Две разные грабли замера

- 1. Не модель:** чужой load на карте, слои ушли на CPU - проверять, кто владелец процесса.
- 2. Модель:** длинная таблица, `truncated=1`, лечится `-c 16384` - размер контекста

БЛОК 5, OCR

OCR-история 3 из 3 · ВЫВОД ИЗ ИСТОРИИ КАНДИДАТА

Как читать карточку модели

Три шага до скачивания, каждый отсеивает свой класс ошибок. Разбор на GLM-OCR: карточка обещала одно, замер показал другое.

1

Лицензия

коммерция? порог аудитории? перепродажа? CC-BY - да, openrail - с условиями, без лицензии - мимо

2

Языки и бенчмарк

GLM-OCR: 94.62 на бенчмарке, русского в supported languages нет - для наших документов уже насторожить должно

3

Живой замер на своих данных

обещали 1.86 стр/с, на этой карте 0.069. Без замера вы бы узнали об этом после внедрения

Правило


Цифра из карточки - это гипотеза, не факт. Гипотеза проверяется одним прогоном на своём файле, и это дешевле, чем откатывать внедрение.

БЛОК 5, ПРОДОЛЖЕНИЕ

ТРЕТИЙ РАБОЧИЙ ПАЙПЛАЙН: генерация изображений, он же сделал обложки этого вебинара

Пайплайн draw: обложки и арты локально

ComfyUI на :8188, Qwen-Image-2.1 int8. Текст в кадре пишется моделью, персонаж держит сходство по референсу - без IP-Adapter. Обложки моих статей сделаны им же.



Экономика и границы

Локально

0 ₽

Карта уже стоит и давно окупилась. Документы и записи не покидают вашу машину: в облаке у загрузки есть читающие её работники. RTX 4060 8 ГБ - минимум, работает только при выгрузке моделей между шагами

Облако

подписка каждый месяц

Тяжёлые задачи, жёсткий срок, свежий контекст из сети - вот когда API оправдан. Всё остальное закрывается локально. Граница локального: русский у трёхмиллиардных моделей плывёт, надёжность - в облаке чат, здесь разбираешься сам

БЛОК 7

Где это уже работает: живая ops-практика

Тот же подход на боевой инфраструктуре, не домашняя лаборатория.



17 контейнеров

Роутинг в git, ветка, ревью, приёмочные проверки - не правка на живом узле



IaC

3 узла кластера за час; ландшафт заказчика пересобран 1-в-1, авария воспроизведена



Бэкап 19/19

PBS как VM на инфраструктуре заказчика, 0 рублей, до 99% чанков переиспользовано



Wildcard

DNS-01, Let's Encrypt - сертификат на весь поддомен тоже 0 рублей



База знаний

Вывод из инцидента в базу, агент подтягивает сам - скиллы под другим именем

Подробнее: [Воркфлоу с DoD и гейтами](#) · [MCP-шлюз](#)

Карта ops-практики

Четыре контура, один принцип: конфигурация в git, проверка до действия, цена - ноль.

Платформа: 17 контейнеров

Прокси → шлюз → векторная база → агенты. Каждая правка: ветка → ревью → приёмочные проверки → применение

Стенды: IaC

Узлы разворачиваются из описаний. Ландшафт заказчика пересобран по его логам один в один - авария воспроизвелась

Данные: бэкап

Внешняя копия на инфраструктуре заказчика, плейбук настройки, 19/19 гостей за ночь, 0 рублей

Знания: база для агентов

Инцидент разобран → вывод записан → агент подтягивает сам. Тот же механизм, что скиллы в Hermes

ИТОГИ

Что взять сегодня же

1

Поставить LM Studio и запустить любую модель на 3 млрд, чтобы посмотреть как это выглядит

2

Написать один скилл под свою повторяющуюся задачу, это пятнадцать минут

3

Прогнать свой PDF через локальный OCR и сравнить с облаком

4

Заложить выгрузку моделей в пайплайн до того, как столкнётесь с нехваткой памяти

Последняя мысль

Инструмент не заменяет знания, он освобождает от рутины, чтобы вы занимались знаниями.

Подробнее: [Цикл по книге Инфанте, ч.1](#) · [ч.4 RAG в глубину](#) · [Код пайплайна аудио: shturman-meeting на GitFlic](#)